



Projet de module

Exploration de données

Détection de fraude par carte bancaire

Réalisé par : Amroug Nisrine
Jouichat Khadija

Encadrant Pédagogique : Pr. NADIR Younes

Dédicaces

Nous avons le grand plaisir et l'honneur de dédier notre travail à ceux qui ont été notre soutien permanent, dont les sacrifices, les encouragements moralement ainsi que matériellement, les précieux conseils nous ont guidé durant notre parcours jusqu'à maintenant.

À nos très chères mères, qui nous donnent toujours l'espoir de vivre ; à nos familles ; à nos chers amis ; à toute personne qui nous a soutenu tout au long de notre formation; c'est avec tout notre amour que nous vous adressons cet hommage.

JOUICHAT Khadija & AMROUG Nisrine

Remerciements

Toute la gratitude, tout d'abord à Allah qui nous a donné la force et la capacité pour terminer ce modeste travail.

À notre encadrant

Nos remerciements les plus sincères vont à M. NADIR Younes, notre encadrant de projet, pour sa confiance, son expertise, son suivi, sa disponibilité, sa sympathie, et ses conseils avisés qui ont donné à ce projet une dimension résolument professionnelle. Son exigence et sa vision opérationnelle ont été déterminantes dans l'élaboration de cette solution de détection de fraude.

À l'EMSI

Nous remercions sincèrement l'ensemble du corps professoral de l'École Marocaine des Sciences de l'Ingénieur pour son environnement académique stimulant et ses ressources pédagogiques de qualité tout au long de notre formation en Ingénierie Informatique et Réseaux, spécialisation IA & Data Science.

À nos familles

Une pensée toute particulière à nos familles pour leur soutien constant tout au long de ce parcours exigeant.

À tous ceux qui, de près ou de loin, ont contribué à la réalisation de ce projet, qu'ils trouvent ici l'expression de notre reconnaissance.

Résumé

Ce projet s'inscrit dans le cadre de la formation en Data Mining de quatrième année à l'École Marocaine des Sciences de l'Ingénieur (EMSI), spécialisation Intelligence Artificielle et Data Science. Il porte sur la détection de fraude par carte bancaire, un problème crucial dans le secteur financier où les transactions frauduleuses causent des pertes considérables chaque année.

L'objectif principal est de développer un modèle de classification binaire capable de distinguer les transactions légitimes des transactions frauduleuses à partir d'un jeu de données anonymisé contenant 284 807 transactions, dont seulement 0,17% sont frauduleuses. Nous avons mis en œuvre une approche complète incluant :

- Une analyse exploratoire détaillée des données (EDA)
- Un prétraitement rigoureux avec standardisation des variables numériques
- L'entraînement et la comparaison de trois modèles : Régression Logistique, Random Forest, et Isolation Forest
- Une évaluation approfondie utilisant des métriques adaptées (F1-score, PR-AUC, ROC-AUC)
- Une analyse de l'impact du seuil de décision sur les performances du modèle

Les résultats montrent que Random Forest offre les meilleures performances avec un F1-score de 0,89 et un PR-AUC de 0,93, démontrant la faisabilité d'une détection efficace des fraudes malgré le déséquilibre extrême des classes.

Mots clés : Détection de fraude, classification déséquilibrée, PR-AUC, Random Forest, Régression Logistique, Isolation Forest, Machine Learning, Data Mining.

Abstract

This project is part of the Data Mining training in the fourth year at the École Marocaine des Sciences de l'Ingénieur (EMSI), specializing in Artificial Intelligence and Data Science. It focuses on credit card fraud detection, a crucial issue in the financial sector where fraudulent transactions cause considerable losses each year.

The main objective is to develop a binary classification model capable of distinguishing legitimate transactions from fraudulent ones, using an anonymized dataset containing 284,807 transactions, of which only 0.17% are fraudulent. We implemented a comprehensive approach that includes:

- A detailed exploratory data analysis (EDA)
- Rigorous preprocessing with standardization of numerical variables
- Training and comparison of three models: Logistic Regression, Random Forest, and Isolation Forest
- Thorough evaluation using appropriate metrics (F1-score, PR-AUC, ROC-AUC)
- Analysis of the impact of the decision threshold on model performance

The results show that Random Forest provides the best performance with an F1-score of 0.89 and a PR-AUC of 0.93, demonstrating the feasibility of effective fraud detection despite the extreme class imbalance.

Keywords: Fraud detection, imbalanced classification, PR-AUC, Random Forest, Logistic Regression, Isolation Forest, Machine Learning, Data Mining.

Table des matières

<i>Dédicaces</i>	2
<i>Remerciements</i>	3
<i>Résumé</i>	4
<i>Abstract</i>	5
<i>Table des matières</i>	6
<i>Liste des figures</i>	9
<i>Liste des tableaux</i>	9
<i>Liste des abréviations</i>	10
<i>Introduction générale</i>	11
Contexte général	11
Problématique	11
Objectifs du projet	11
Organisation du rapport	12
<i>I. Présentation du projet et du dataset</i>	13
I.1. Introduction du chapitre	13
I.2. Présentation du domaine d'application	Erreur ! Signet non défini.
I.3. Présentation du problème étudié	14
I.4. Présentation du dataset	14
I.5. Description des variables	15
I.6. Objectifs analytiques du projet	15
I.7. Planning du travail	15
I.8. Conclusion du chapitre	16
<i>II. Analyse exploratoire et préparation des données</i>	17
II.1. Introduction du chapitre	17
II.2. Chargement et aperçu initial des données	17

II.3.	Analyse de la variable cible	18
II.4.	Analyse exploratoire des variables	19
II.5.	Qualité des données	21
II.6.	Feature engineering	21
II.7.	Prétraitement des données	22
II.8.	Conclusion du chapitre	23
III.	Modélisation, expérimentation et évaluation	24
III.1.	Introduction du chapitre	24
III.2.	Choix des algorithmes	24
III.3.	Protocole expérimental	24
III.4.	Métriques d'évaluation	25
III.5.	Résultats obtenus	25
III.6.	Analyse des erreurs	26
III.7.	Sélection du meilleur modèle	26
III.8.	Conclusion du chapitre	27
IV.	Interprétation, limites et reproductibilité	28
IV.1.	Introduction du chapitre	28
IV.2.	Interprétation des résultats	28
IV.3.	Discussion métier ou applicative	28
IV.4.	Limites du travail	28
IV.5.	Améliorations possibles	29
IV.6.	Reproductibilité du projet	29
IV.7.	Structure obligatoire du notebook	30
IV.8.	Conclusion du chapitre	30
	Conclusion générale	31
	Bibliographie et Nétographie	32

Bibliographie	32
Nétographie	32
ANNEXES	33
Annexe A — Notebook	33
Annexe B — Dataset	33
Annexe C — Requirements.txt	33
Annexe D — Figures complémentaires	33
<i>Guide de mise en forme — Référence rapide</i>	34
<i>Checklist finale avant remise</i>	34

Liste des figures :

Figure 1: Distribution des classes(0 = normale, 1 = fraude)	19
Figure 2: Montant des transactions par classe (échelle log).....	19
Figure 3: Matrice de corrélation (échantillon de 1000 transactions).....	20
Figure 4: Distribution de Time par classe	20

Liste des tableaux

Tableau 1: Liste des abréviations	10
Tableau 2: Synthèse du problème étudié.....	14
Tableau 3: Description générale du dataset.....	14
Tableau 4: Dictionnaire simplifié des variables	15
Tableau 5: Planning prévisionnel du projet Data Mining	16
Tableau 6: Vérifications initiales du dataset	17
Tableau 7: Synthèse de la qualité des données	21
Tableau 8: Variables dérivées proposées	21
Tableau 9: Synthèse du prétraitement	22
Tableau 10: Choix des algorithmes selon le type de tâche.....	24
Tableau 11: Protocole expérimental.....	24
Tableau 12: Métriques recommandées selon la tâche	25
Tableau 13: Résultats comparés des modèles sur le jeu de test (seuil = 0,5).....	25
Tableau 14: Comparaison des seuils de décision (Logistic Regression).....	25
Tableau 15: Informations de reproductibilité	29
Tableau 16: Structure obligatoire du notebook	30

Liste des abréviations

Tableau 1: Liste des abréviations

Abréviation	Signification
EDA	Exploratory Data Analysis / Analyse exploratoire des données
ML	Machine Learning
RMSE	Root Mean Squared Error
Seuil 0,5 (défaut)	Mean Absolute Error
F1-score	Moyenne harmonique de la précision et du rappel
ROC-AUC	Aire sous la courbe ROC
PR-AUC	Aire sous la courbe Precision-Recall

Introduction générale

Contexte général

Ce projet appartient au domaine de la finance, et plus spécifiquement à la détection de fraude bancaire. Les transactions par carte bancaire représentent aujourd'hui un volume considérable dans les systèmes financiers modernes. Bien que la majorité de ces opérations soient légitimes, une minorité de transactions frauduleuses peut entraîner des pertes financières importantes et affecter la confiance des clients envers les institutions. L'analyse de données et le Data Mining jouent ici un rôle crucial : ils permettent de traiter de grands volumes de données, de mettre en évidence des comportements atypiques et de construire des modèles prédictifs capables d'identifier les fraudes en temps réel. Ces techniques offrent aux banques et aux organismes financiers des outils puissants pour réduire les risques, améliorer la sécurité et protéger les utilisateurs.

Problématique

La problématique centrale peut être formulée ainsi : comment détecter efficacement des fraudes rares dans un grand volume de transactions bancaires, en tenant compte du déséquilibre extrême entre les classes et en minimisant le coût métier des erreurs ? Il s'agit d'une tâche de classification supervisée, où l'objectif est de distinguer les transactions normales des transactions frauduleuses. Cependant, la rareté des fraudes rapproche également cette problématique de la détection d'anomalies, car les observations frauduleuses constituent des cas atypiques par rapport à la majorité des données. L'enjeu principal est de réduire au maximum les faux négatifs (fraudes non détectées, entraînant des pertes financières directes) tout en limitant les faux positifs (transactions légitimes bloquées, entraînant une gêne pour les clients).

Objectifs du projet

- ▶ comprendre le dataset et sa source ;
 - ▶ analyser les variables et la cible éventuelle ;
 - ▶ nettoyer et préparer les données ;
 - ▶ réaliser une analyse exploratoire commentée ;
 - ▶ construire un ou plusieurs modèles adaptés ;
 - ▶ évaluer les performances avec des métriques pertinentes ;
 - ▶ interpréter les résultats et discuter les limites.
-

Organisation du rapport

Le présent rapport est structuré en quatre chapitres :

1. Le premier chapitre présente le contexte général du projet, incluant la formation à l'EMSI, les enjeux de la détection de fraude, et la problématique scientifique.
 2. Le deuxième chapitre dresse un état de l'art des méthodes de détection de fraude bancaire, en s'appuyant sur la littérature académique.
 3. Le troisième chapitre détaille la méthodologie adoptée, depuis l'analyse exploratoire des données jusqu'à la sélection et l'entraînement des modèles.
 4. Le quatrième chapitre présente les résultats obtenus, leur interprétation, une analyse critique des performances, ainsi que les limites et les perspectives d'amélioration.
-

I. Présentation du projet et du dataset

I.1. Introduction du chapitre

Ce chapitre présente le projet de détection de fraude par carte bancaire ainsi que le dataset utilisé pour sa mise en œuvre. Après avoir introduit le domaine d'application et les enjeux liés à la sécurité des transactions financières, nous décrirons les caractéristiques principales des données mises à disposition. Cette présentation constitue une étape essentielle pour comprendre la nature du problème étudié et les contraintes spécifiques liées au déséquilibre des classes. Elle permet également d'assurer une transition claire entre l'introduction générale du rapport et l'analyse détaillée des méthodes de traitement et de modélisation qui seront développées dans les sections suivantes

I.2. Présentation du domaine d'application

Le projet étudié s'inscrit dans le domaine de la finance, et plus précisément dans la banque de détail. Les transactions par carte bancaire constituent aujourd'hui un mode de paiement incontournable, utilisé quotidiennement par des millions de clients à travers le monde. Ce volume élevé de données rend le système particulièrement vulnérable aux tentatives de fraude, qui bien que rares, peuvent avoir des conséquences financières et réputationnelles majeures pour les institutions bancaires.

Dans ce contexte, l'analyse de données et le Data Mining apportent une valeur ajoutée essentielle. Ils permettent de traiter efficacement des ensembles massifs de transactions, d'identifier des schémas récurrents et de mettre en évidence des comportements atypiques pouvant correspondre à des fraudes. L'intérêt métier est double : réduire les pertes financières liées aux opérations frauduleuses et renforcer la confiance des clients dans les services bancaires. Sur le plan scientifique, ce type de problématique illustre les défis liés aux données déséquilibrées et à la détection d'anomalies, offrant un terrain d'expérimentation riche pour les méthodes de classification supervisée et non supervisée.

I.3. Présentation du problème étudié

Tableau 2: Synthèse du problème étudié

Élément	Description attendue
Problème à résoudre	Détecter efficacement les transactions frauduleuses dans un grand volume de données bancaires déséquilibrées.
Type de tâche	Classification supervisée (avec aspects de détection d'anomalies).
Variable cible	Class (0 = non-fraude, 1 = fraude).
Intérêt du modèle	Réduction des pertes financières, amélioration de la sécurité bancaire, illustration pédagogique des méthodes de classification en contexte déséquilibré.

I.4. Présentation du dataset

Tableau 3: Description générale du dataset

Élément	Description
Nom du dataset	Credit Card Fraud Detection (creditcard.csv)
Source	Kaggle
Lien officiel	https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud (kaggle.com in Bing)
Domaine	Finance / Banque / Fraude
Nombre de lignes	284 807 transactions
Nombre de colonnes	31 variables (Time, Amount, V1–V28, Class)
Type de tâche	Classification supervisée (fraude vs non-fraude)

Variable cible	Class (0 = transaction légitime, 1 = transaction frauduleuse)
----------------	---

I.5. Description des variables

Tableau 4: Dictionnaire simplifié des variables

Variable	Type	Description	Rôle
Time	Numérique	Temps écoulé depuis la première transaction (en secondes).	Feature
Amount	Numérique	Montant de la transaction.	Feature
V1-V28	Numérique	Variables anonymisées issues d'une PCA, représentant des caractéristiques.	Feature
Class	Numérique	Variable cible : 0 = légitime, 1 = fraude.	Cible

I.6. Objectifs analytiques du projet

Les objectifs analytiques de ce projet consistent tout d’abord à explorer la structure du dataset afin de comprendre la nature des variables disponibles et leur distribution. Cette étape permet d’identifier les variables importantes pour la détection de fraude et de repérer celles qui nécessitent un traitement particulier. Dans un second temps, il s’agit de corriger les éventuelles incohérences présentes dans les données, en traitant les valeurs manquantes, les doublons et les anomalies.

Une autre étape essentielle consiste à créer des variables dérivées pertinentes, susceptibles d’améliorer la performance des modèles en capturant des comportements spécifiques liés aux transactions frauduleuses. Par la suite, plusieurs modèles de classification et de détection d’anomalies seront comparés afin d’évaluer leur efficacité dans ce contexte de données fortement déséquilibrées.

La sélection de l’approche retenue se fera sur la base de métriques adaptées, telles que le rappel, le F1-score, le ROC-AUC et surtout le PR-AUC, qui est plus pertinent dans le cas d’un déséquilibre extrême. Enfin, les résultats obtenus devront être interprétés de manière critique, en mettant en évidence les limites des modèles et en discutant du coût métier des erreurs, notamment l’impact des faux négatifs et des faux positifs dans un contexte bancaire.

I.7. Planning du travail

Tableau 5: Planning prévisionnel du projet Data Mining

Étape	S1	S2	S3	S4
Recherche et validation du dataset	X			
Compréhension du problème	X			
Analyse exploratoire	X	X		
Nettoyage des données		X		
Prétraitement		X	X	
Modélisation			X	
Évaluation			X	X
Interprétation et rapport				X

I.8. Conclusion du chapitre

Ce premier chapitre a permis de présenter le projet de détection de fraude par carte bancaire, en situant son domaine d'application dans la finance et en mettant en évidence les enjeux liés à la sécurité des transactions. La problématique centrale repose sur la difficulté de détecter des fraudes rares dans un volume massif de données, ce qui en fait un cas typique de classification supervisée en contexte fortement déséquilibré. Le dataset utilisé, issu de Kaggle, a été décrit dans ses principales caractéristiques : variables anonymisées par PCA, variables explicites telles que Time et Amount, ainsi que la cible Class. Les objectifs analytiques ont été définis afin de guider l'ensemble du travail, depuis l'exploration des données jusqu'à l'interprétation des résultats.

Cette conclusion marque la transition vers le chapitre suivant, consacré à l'analyse exploratoire et au prétraitement des données. Ce dernier constituera une étape essentielle pour comprendre

la structure du dataset, identifier les particularités liées au déséquilibre des classes et préparer les données en vue de la modélisation.

II. Analyse exploratoire et préparation des données

II.1. Introduction du chapitre

Ce deuxième chapitre est consacré à l’analyse exploratoire et à la préparation des données. Il s’agit d’une étape essentielle dans tout projet de Data Mining, car elle permet de comprendre la structure du dataset, d’évaluer la qualité des données disponibles et d’identifier les éventuelles incohérences. L’exploration inclut la visualisation des distributions, la détection des valeurs manquantes ou aberrantes, ainsi que l’étude des corrélations entre variables. Parallèlement, des traitements préparatoires sont appliqués afin de rendre les données exploitables pour la modélisation, notamment la standardisation de certaines variables et la mise en place d’un découpage stratifié en ensembles d’entraînement et de test. Ce chapitre constitue donc la transition entre la présentation générale du projet et les étapes de modélisation, en garantissant que les données utilisées sont fiables et adaptées aux objectifs analytiques.

II.2. Chargement et aperçu initial des données

Tableau 6: Vérifications initiales du dataset

Élément à vérifier	Commande ou action attendue
Dimensions	df.shape
Aperçu des données	df.head()
Types des colonnes	df.info()
Statistiques descriptives	df.describe()
Source du dataset	Lien officiel + nom exact du fichier

Le chargement des données constitue une étape de validation indispensable. Il permet de confirmer que le dataset est conforme à la source officielle et qu'il contient bien les variables nécessaires (Time, Amount, V1–V28, Class). Ces vérifications initiales garantissent la fiabilité du jeu de données avant de passer à l'analyse exploratoire détaillée.

II.3. Analyse de la variable cible

Dans ce projet, la tâche est une classification supervisée et la variable cible est Class. Elle prend deux valeurs :

- 0 pour une transaction légitime,
- 1 pour une transaction frauduleuse.

L'analyse de la distribution de cette variable montre un déséquilibre extrême : sur les 284 807 transactions, seules 492 sont frauduleuses, soit environ 0,17 % du total. Ce déséquilibre a un impact direct sur le choix des métriques d'évaluation. En effet, l'accuracy n'est pas pertinente dans ce contexte, car un modèle qui prédirait systématiquement "non-fraude" atteindrait une précision supérieure à 99 % tout en échouant totalement à détecter les cas critiques.

Il est donc indispensable de privilégier des métriques adaptées telles que le recall (pour mesurer la capacité à identifier les fraudes), le F1-score (équilibre entre précision et rappel), le ROC-AUC et surtout le PR-AUC, qui est plus représentatif dans les situations de classes fortement déséquilibrées.




Figure 1: Distribution des classes(0 = normale, 1 = fraude)

- Cette visualisation met en évidence le déséquilibre extrême entre les deux classes. La classe majoritaire (normale) représente 99,83% des transactions. Ce déséquilibre justifie l'utilisation de métriques adaptées (PR-AUC, F1-score) plutôt que l'accuracy.

II.4. Analyse exploratoire des variables

Analyse du montant des transactions :




Figure 2: Montant des transactions par classe (échelle log)

Matrice de corrélation :




Figure 3: Matrice de corrélation (échantillon de 1000 transactions)

- La matrice révèle une faible corrélation entre les variables V1 à V28 (effet attendu de la PCA). Certaines variables V sont corrélées avec Class, notamment V1, V2, V3, V4, V10, V11, V12, V14, V17.

Analyse de la variable Time :




Figure 4: Distribution de Time par classe

- Les transactions frauduleuses sont distribuées de manière relativement uniforme sur l'ensemble de la période. La variable Time ne semble pas être un discriminant majeur, mais peut contribuer à la détection en capturant des schémas temporels.

II.5. Qualité des données

Tableau 7: Synthèse de la qualité des données

Problème détecté	Colonnes concernées	Traitement appliqué	Justification
Valeurs manquantes	Aucune	Aucun traitement nécessaire	Le dataset est complet, aucune imputation ou suppression n'est requise.
Doublons	Aucun	Aucun traitement nécessaire	Chaque transaction est unique, pas de redondance.
Outliers	Amount	Conservation	Les valeurs extrêmes peuvent être caractéristiques de fraudes.
Fuite de données	Aucune	Non applicable	Le dataset ne contient pas de variable risquant de révéler directement la cible.

II.6. Feature engineering

Tableau 8: Variables dérivées proposées

Variable dérivée	Formule / construction	Intérêt analytique
TransactionHour	$(df['Time'] \% (24 * 3600)) / 3600$	Capturer les modèles cycliques quotidiens de l'activité frauduleuse.
TransactionDay	$df['Time'] // (24 * 3600)$	Identifier les changements dans le comportement des transactions ou les schémas de fraude entre les jours distincts de la période de collecte des données.

En complément des variables existantes, deux nouvelles variables dérivées ont été créées à partir de la variable `Time`, afin d'exploiter l'information temporelle souvent cruciale dans la détection de fraude :

- `TransactionHour` : correspond à l'heure de la journée (0–23) calculée à partir du temps en secondes. Bien que `Time` soit une mesure relative, cette transformation permet de mettre en évidence des schémas cycliques dans les transactions. Les fraudes peuvent en effet se concentrer à certaines heures atypiques (par exemple la nuit).
- `TransactionDay` : indique si la transaction a eu lieu le premier jour (0) ou le second jour (1) de la période de collecte. Cette variable permet de vérifier si les fraudes sont plus fréquentes à un moment particulier du cycle de collecte.

Ces variables enrichissent l'analyse en introduisant une dimension comportementale. Elles permettent de tester l'hypothèse selon laquelle les fraudes suivent des patterns temporels spécifiques.

II.7. Prétraitement des données

Tableau 9 Synthèse du prétraitement

Traitement	Méthode utilisée	Justification
Séparation X/y	<code>df.drop('Class', axis=1, df['Class'])</code>	Définir les features (X) et la variable cible (y) pour l'apprentissage supervisé.
Feature Engineering	Création de <code>TransactionHour</code> et <code>TransactionDay</code>	Extraire des informations temporelles cycliques (heure de la journée) et par jour pour enrichir le modèle et capturer des schémas de fraude spécifiques au temps.
Standardisation	<code>StandardScaler</code>	Mettre à l'échelle les variables numériques (<code>Amount</code> , <code>Time</code> , <code>TransactionHour</code> , <code>TransactionDay</code>) pour éviter que les modèles ne soient dominés par des variables ayant de plus grandes échelles.
Split Train/Test	<code>train_test_split</code> (stratifié sur y)	Évaluer la performance du modèle sur des données non vues, en assurant que la proportion des classes (fraude/non-fraude) est maintenue dans les ensembles d'entraînement et de test.

II.8. Conclusion du chapitre

Ce chapitre a couvert l'exploration et la préparation des données.

Constats clés de l'EDA :

1. Déséquilibre Extrême des Classes : Le dataset présente un déséquilibre sévère (0.17% de fraudes), nécessitant des métriques spécifiques et des techniques de rééquilibrage.
2. Patterns Temporels et Montants : Les transactions frauduleuses montrent des distributions distinctes en termes de montants (généralement plus faibles) et de Time (patterns horaires spécifiques).
3. Features V : Les variables V anonymisées sont corrélées à la classe cible et sont importantes pour la détection.

Qualité des Données et Problèmes Corrigés :

- Le dataset est propre : aucune valeur manquante ni doublon, et aucune variable catégorielle n'est présente, simplifiant l'étape de nettoyage.

Préparation des Données pour la Modélisation :

1. Feature Engineering : Création de TransactionHour et TransactionDay pour mieux capturer les informations temporelles cycliques.
2. Standardisation : Les variables numériques (Amount, Time, TransactionHour, TransactionDay) ont été standardisées avec StandardScaler.
3. Séparation Train/Test Stratifiée : Le jeu de données a été divisé de manière stratifiée sur la classe cible pour garantir une répartition représentative des fraudes dans les ensembles d'entraînement et de test.

Ces étapes ont permis de disposer d'un dataset enrichi et prêt pour la modélisation.

III. Modélisation, expérimentation et évaluation

III.1. Introduction du chapitre

Ce chapitre est dédié à la mise en œuvre de différents modèles de détection de fraude, à l'expérimentation de leurs paramètres et à l'évaluation de leurs performances. Nous allons explorer les algorithmes choisis, les métriques d'évaluation pertinentes pour un jeu de données déséquilibré, et analyser en détail les résultats obtenus pour identifier le modèle le plus adapté à notre problématique de détection de fraude bancaire.

III.2. Choix des algorithmes

Tableau 10: Choix des algorithmes selon le type de tâche

Type de tâche	Algorithmes possibles
Classification	Logistic Regression, Decision Tree, Random Forest, SVM, Gradient Boosting, KNN
Régression	Linear Regression, Ridge, Lasso, ElasticNet, Random Forest Regressor, Gradient Boosting Regressor
Clustering	K-Means, clustering hiérarchique, DBSCAN si pertinent
Analyse de paniers	Apriori, FP-Growth, règles d'association
Détection d'anomalies	Isolation Forest, Local Outlier Factor, seuil statistique, modèles temporels simples

III.3. Protocole expérimental

Tableau 11: Protocole expérimental

Élément	Description
Taille du train set	227 845 transactions (80 %)
Taille du test set	56 962 transactions (20 %)
Type de split	Stratifié sur la variable cible Class (stratify=y, random_state=42)
Validation croisée	Non utilisée (split unique train/test, évalué sur l'ensemble de test)
Pipeline	Non (standardisation appliquée manuellement avant le split, sur X complet)
Bibliothèques principales	pandas, numpy, scikit-learn, matplotlib, seaborn, kagglehub

III.4. Métriques d'évaluation

Tableau 12: Métriques recommandées selon la tâche

Type de tâche	Métriques recommandées
Classification équilibrée	Accuracy, precision, recall, F1-score, matrice de confusion
Classification déséquilibrée	Recall, F1-score, ROC-AUC, PR-AUC, matrice de confusion, analyse de seuil
Régression	MAE, RMSE, R², analyse des résidus
Clustering	Inertia, silhouette score, méthode du coude, interprétation métier
Anomalies	Taux d'anomalies, justification du seuil, analyse visuelle, interprétation

III.5. Résultats obtenus

Tableau 13: Résultats comparés des modèles sur le jeu de test (seuil = 0,5)

Modèle	Accuracy	Precision	Recall	F1-score	ROC-AUC
Logistic Regression	0,9791	0,0604	0,9184	0,1133	0,9488
Isolation Forest	0,9890	0,0249	0,3061	0,0450	0,6529
Random Forest	0,9996	0,9286	0,8571	0,8916	0,9276
PR-AUC (métrique principale)	LR : 0,0617	IF : 0,0249	RF : 0,9301		

Tableau 14: Comparaison des seuils de décision (Logistic Regression)

Métrique	Seuil 0,3 (optimisé)	Impact métier	
Recall (fraudes détectées)	0,9184	0,9490	Moins de fraudes manquées
Precision	0,0604	0,0320	Plus de faux positifs

F1-score	0,1133	0,0618	Équilibre précision/rappel dégradé
----------	--------	--------	--

III.6. Analyse des erreurs

- Classification : les faux négatifs (fraudes non détectées) représentent le risque le plus grave. Pour la Logistic Regression au seuil 0,5, 8 fraudes sur 98 sont manquées. En abaissant le seuil à 0,3, ce nombre tombe à environ 5, au prix d'une hausse des faux positifs. Random Forest affiche la meilleure matrice de confusion avec seulement 14 faux négatifs et très peu de faux positifs. Isolation Forest présente un nombre élevé de faux positifs car, sans étiquetage, il ne distingue pas finement les anomalies rares des simples variations normales.
- Faux négatifs (fraudes manquées) : ce sont les erreurs les plus coûteuses métier. Chaque fraude non détectée représente une perte financière directe pour la banque. La stratégie de seuil visée doit minimiser ce type d'erreur.
- Faux positifs (transactions légitimes bloquées) : leur coût est plus modéré (insatisfaction client, appel service client), mais doit rester contrôlé. L'abaissement du seuil de décision à 0,3 multiplie par environ 2 les faux positifs tout en améliorant significativement le recall.
- Isolation Forest : modèle non supervisé adapté à la détection d'anomalies sans étiquettes, mais ses performances restent inférieures aux modèles supervisés sur ce jeu de données étiqueté. Il constitue néanmoins une approche complémentaire utile dans des contextes où le labelling est impossible.

III.7. Sélection du meilleur modèle

Le modèle retenu est le Random Forest avec `class_weight='balanced'`. Il offre les meilleures performances sur toutes les métriques clés adaptées au déséquilibre de classes : F1-score de 0,8916, PR-AUC de 0,9301 et ROC-AUC de 0,9276. Comparé à la Régression Logistique, il gère bien mieux la non-linéarité des données et produit des probabilités mieux calibrées, ce qui permet une analyse de seuil plus fine. Comparé à l'Isolation Forest, il bénéficie de l'information des étiquettes et atteint un recall nettement supérieur. Son inconvénient principal est le temps d'entraînement plus élevé et la faible interprétabilité directe, mais ces éléments sont secondaires dans un contexte où la performance de détection prime.

III.8. Conclusion du chapitre

Ce chapitre a présenté la mise en œuvre complète de trois modèles de détection de fraude : la Régression Logistique (avec `class_weight='balanced'`), le Random Forest (avec `class_weight='balanced'`) et l'Isolation Forest (approche non supervisée). Le protocole expérimental a respecté les exigences du projet : split stratifié 80/20, aucun échantillonnage avant le split, et évaluation strictement sur l'ensemble de test. Les métriques retenues (Recall, F1-score, ROC-AUC et PR-AUC) sont adaptées au contexte de déséquilibre extrême, l'accuracy étant explicitement écartée. L'analyse de deux seuils de décision (0,5 et 0,3) a illustré le compromis précision/rappel et le coût métier des faux négatifs. Le Random Forest s'est imposé comme le meilleur modèle avec un PR-AUC de 0,93, confirmant la faisabilité d'une détection efficace malgré la rareté des fraudes. Le chapitre suivant approfondit l'interprétation de ces résultats, leurs limites et les pistes d'amélioration.

IV. Interprétation, limites et reproductibilité

IV.1. Introduction du chapitre

Ce chapitre présente l'interprétation des résultats obtenus, leur portée dans le contexte de la détection de fraude bancaire, les limites du travail réalisé ainsi que les conditions nécessaires à la reproductibilité du projet. L'objectif est de transformer les résultats numériques obtenus lors de la modélisation en conclusions exploitables d'un point de vue analytique et métier.

IV.2. Interprétation des résultats

L'analyse des résultats montre que les modèles supervisés sont nettement plus performants que l'approche non supervisée dans ce contexte. Cette différence s'explique par la disponibilité des étiquettes de fraude qui permettent aux modèles supervisés d'apprendre directement les caractéristiques associées aux transactions frauduleuses.

L'étude exploratoire a mis en évidence plusieurs variables anonymisées (notamment V1, V2, V3, V4, V10, V11, V12, V14 et V17) présentant une corrélation plus importante avec la variable cible. Bien que leur signification réelle ne soit pas connue en raison de l'anonymisation par PCA, elles semblent contenir une part importante de l'information discriminante utilisée par les modèles.

Les transactions frauduleuses présentent généralement des montants plus faibles que les transactions légitimes. L'analyse de la variable Time suggère également l'existence de certains schémas temporels, même si cette variable n'apparaît pas comme un facteur déterminant à elle seule.

L'étude des seuils de décision montre qu'un seuil plus faible permet d'augmenter le rappel et donc de détecter davantage de fraudes. Cette amélioration se fait toutefois au prix d'une augmentation des faux positifs. Dans un contexte bancaire, cette stratégie est souvent acceptable car le coût d'une fraude non détectée est généralement supérieur au coût d'une vérification supplémentaire.

IV.3. Discussion métier ou applicative

Dans un contexte bancaire réel, un système de détection de fraude constitue un outil d'aide à la décision permettant d'identifier rapidement les transactions suspectes. Les résultats obtenus montrent qu'il est possible de détecter efficacement une grande partie des fraudes malgré leur très faible proportion dans le dataset. Les faux négatifs représentent le coût métier le plus important puisqu'ils correspondent à des fraudes non détectées. À l'inverse, les faux positifs engendrent principalement une gêne client et des coûts de vérification supplémentaires. Le modèle Random Forest apparaît comme le meilleur compromis entre détection efficace et limitation des alertes inutiles.

IV.4. Limites du travail

Malgré les résultats satisfaisants obtenus, plusieurs limites doivent être mentionnées. Premièrement, le dataset utilisé couvre uniquement deux jours de transactions et ne représente pas nécessairement les comportements actuels des fraudeurs. Deuxièmement, les variables V1 à V28 ont été anonymisées par PCA. Cette anonymisation protège la confidentialité des données mais réduit fortement l'interprétabilité métier. Troisièmement, le déséquilibre extrême des classes constitue une difficulté importante. Avec seulement 492 fraudes sur 284 807 transactions, l'apprentissage reste complexe et certaines métriques peuvent être sensibles aux variations du jeu de données. Enfin, les performances ont été évaluées sur un unique jeu de test provenant de la même source que les données d'entraînement. Une validation sur des données externes serait nécessaire pour confirmer la robustesse du modèle.

IV.5. Améliorations possibles

Plusieurs pistes d'amélioration peuvent être envisagées. L'optimisation des hyperparamètres à l'aide de Grid Search ou Random Search pourrait améliorer les performances des modèles. Il serait également pertinent de comparer différentes techniques de rééquilibrage telles que SMOTE ou l'undersampling contrôlé, appliquées uniquement à l'ensemble d'entraînement conformément aux bonnes pratiques. Des algorithmes plus avancés tels que XGBoost, LightGBM ou CatBoost pourraient également être évalués. Enfin, une validation croisée stratifiée ainsi qu'un déploiement dans une interface de démonstration permettraient de renforcer respectivement la robustesse expérimentale et l'utilité opérationnelle du projet.

IV.6. Reproductibilité du projet

Tableau 15: Informations de reproductibilité

Élément	Information attendue
Lien source du dataset	https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud (kaggle.com in Bing)
Nom exact du fichier	creditcard.csv
Chemin relatif	data/creditcard.csv
Version Python	Python 3.11
Bibliothèques	pandas, numpy, matplotlib, seaborn, scikit-learn, kagglehub
requirements.txt	Présent

Instruction d'exécution

pip install -r requirements.txt puis exécution du notebook

IV.7. Structure obligatoire du notebook

Tableau 16: Structure obligatoire du notebook

Section du notebook	Rôle attendu
01_import_libraries	Importation propre des bibliothèques
02_load_dataset	Chargement du dataset et preuve de la source
03_problem_understanding	Reformulation de la problématique
04_dataset_description	Description des variables, dimensions et cible
05_exploratory_data_analysis	Statistiques, visualisations et commentaires
06_data_quality_and_cleaning	Valeurs manquantes, doublons, incohérences et outliers
07_preprocessing	Encodage, normalisation, split et pipeline
08_modeling_or_clustering	Application des méthodes demandées
09_evaluation	Métriques adaptées, tableaux et figures
10_interpretation_and_limits	Interprétation, limites et pistes d'amélioration

IV.8. Conclusion du chapitre

Ce chapitre a permis d'interpréter les performances des modèles étudiés et d'évaluer leur intérêt dans un contexte réel de détection de fraude bancaire. Les résultats montrent que les modèles supervisés, et en particulier Random Forest, sont capables de détecter efficacement les transactions frauduleuses malgré le déséquilibre extrême du dataset. Plusieurs limites ont néanmoins été identifiées, ouvrant la voie à des améliorations futures telles que l'utilisation de SMOTE, l'optimisation des hyperparamètres et l'expérimentation d'algorithmes plus avancés.

Conclusion générale

Ce projet avait pour objectif de développer un système capable de détecter des transactions frauduleuses dans un contexte de déséquilibre extrême des classes. À partir du dataset Credit Card Fraud Detection, une démarche complète de Data Mining a été mise en œuvre, comprenant l'analyse exploratoire des données, le prétraitement, la modélisation et l'évaluation des performances.

Trois approches ont été comparées : la Régression Logistique, Random Forest et Isolation Forest. Les résultats ont été évalués à l'aide de métriques adaptées aux données déséquilibrées, notamment le Recall, le F1-score, le ROC-AUC et le PR-AUC. Les expérimentations ont montré que Random Forest constitue le modèle le plus performant avec un F1-score d'environ 0,89 et un PR-AUC proche de 0,93.

L'étude a également mis en évidence l'importance de la stratégie de seuil dans la détection de fraude. Une diminution du seuil permet d'augmenter le taux de détection des fraudes mais génère davantage de faux positifs. Cette observation illustre le compromis nécessaire entre sécurité et expérience utilisateur dans les systèmes bancaires.

Malgré certaines limites liées au dataset et à son anonymisation, les résultats obtenus démontrent la pertinence des techniques de Machine Learning pour la détection de fraude bancaire. Les perspectives futures incluent l'utilisation de méthodes avancées de rééquilibrage, l'optimisation des hyperparamètres, l'évaluation sur des données plus récentes ainsi que l'intégration du modèle dans un système opérationnel de surveillance en temps réel.

Bibliographie et Nétographie

Bibliographie

- [1] Dal Pozzolo, Andrea et al. *Credit Card Fraud Detection: A Realistic Modeling and a Novel Learning Strategy*. IEEE Transactions on Neural Networks and Learning Systems.
- [2] Han, Jiawei, Kamber, Micheline & Pei, Jian. *Data Mining: Concepts and Techniques*. Morgan Kaufmann.

Nétographie

- [3] <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud> ([kaggle.com in Bing](#))
Kaggle – Credit Card Fraud Detection Dataset.
- [4] <https://scikit-learn.org/stable/index.html> Scikit-learn Documentation – Logistic Regression.
- [5] Scikit-learn Documentation – Random Forest.
- [6] Scikit-learn Documentation – Isolation Forest.
- [7] Imbalanced-Learn Documentation – SMOTE.
-

ANNEXES

Annexe A — Notebook

Lien github : [data_mining_project](#)

Annexe B — Dataset

Nom du fichier : creditcard.csv

Source :

Kaggle – Credit Card Fraud Detection Dataset

Lien :

<https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>

Méthode de téléchargement :

Le dataset a été téléchargé depuis la plateforme Kaggle puis importé dans l'environnement Google Colab à l'aide de la bibliothèque kagglehub.

Annexe C — Requirements.txt

A screenshot of a code editor with a dark background. The file name 'requirements.txt' is shown at the top left. The code is a list of Python dependencies, each preceded by a line number from 1 to 10. The dependencies are: kagglehub, pandas, numpy, matplotlib, seaborn, scikit-learn, jupyter, ipykernel, and imbalanced-learn. The text is color-coded: line numbers are white, and the package names are in a light blue/cyan color.

```
1 kagglehub
2 pandas
3 numpy
4 matplotlib
5 seaborn
6 scikit-learn
7 jupyter
8 ipykernel
9 imbalanced-learn
10
```

Guide de mise en forme — Référence rapide

Tableau 17 : Règles de mise en forme

Paramètre de mise en forme	Consigne
Police du corps	Times New Roman, 12 pt, noir
Interligne	1,5 ligne
Espacement paragraphe	Avant : 6 pt — Après : 6 pt
Alignement	Justifié
Marges	2,5 cm haut, bas, gauche, droite
Titre de chapitre	Arial, 18 pt, gras, couleur institutionnelle
Sous-titre	Arial, 14 pt, gras
Sous-sous-titre	Arial, 12 pt, gras
Légende figure	Arial, 10 pt, italique, sous la figure
Légende tableau	Arial, 10 pt, italique, au-dessus du tableau

Checklist finale avant remise

🔍 **Guideline** : Cette liste peut être utilisée par l'étudiant avant le dépôt du projet.

- ☐ Le lien source du dataset est indiqué dans le rapport et dans le notebook.
- ☐ Le notebook s'exécute du début à la fin sans erreur.
- ☐ Le dataset est chargé avec un chemin relatif ou une méthode reproductible.
- ☐ La problématique est clairement formulée.
- ☐ La cible est identifiée si le projet est supervisé.
- ☐ Les variables sont décrites.
- ☐ Les valeurs manquantes sont traitées ou justifiées.
- ☐ Les outliers sont analysés.
- ☐ Les visualisations sont commentées en français.

-
- ☐ Les choix de nettoyage sont justifiés.
 - ☐ Les modèles sont adaptés au type de tâche.
 - ☐ Les métriques sont adaptées au problème.
 - ☐ Les résultats sont interprétés.
 - ☐ Les limites sont discutées.
 - ☐ Le fichier requirements.txt est fourni.
 - ☐ Les annexes contiennent les éléments complémentaires nécessaires.
-

Bibliographie complémentaire et Nétographie

[1] Dal Pozzolo, A. et al. Credit Card Fraud Detection: A Realistic Modeling and a Novel Learning Strategy. IEEE Transactions on Neural Networks and Learning Systems.

[2] Dataset Kaggle Credit Card Fraud Detection.

[3] Documentation Scikit-learn : Logistic Regression, Random Forest, Isolation Forest.

[4] Documentation imbalanced-learn (SMOTE).
